Tartalomjegyzék

Bevezetés

Az assembly programnyelvek egyszerű, processzor-közeli utasításokból épülnek fel, amiket a számítógép hatékonyan végre tud hajtani, viszont ennek a hatékonyságnak ára van: a program kódja már rövidebb programok esetén is nehezen olvashatóvá és értelmezhetővé válik.

Jelen program feladata az, hogy egy assembly programkód futását szimulálja: az utasításokat egyenként hajtja végre és minden lépés után a felhasználó számára kijelzi az aktuálisan tárolt adatokat: a regiszterek tartalmát, a változók tömbjét és a futásidejű vermet. Elsődlegesen azok számára készült, akik érdeklődnek az assembly nyelvek iránt, de a nehézkes átláthatóság és a túlnyomórészt alacsony szintű utasítások miatt nem teljesen értik a műveleteket és nehezükre esik elképzelni, hogy mi történik az utasítások hatására.

Felhasználói dokumentáció

A program célja

A program beolvas egy egy NASM assembly utasításokból álló fájlt, annak a programnak a futását szimulálja, azaz a kódot lépésenként hajtja végre és minden lépés után kijelzi a regiszterekben, a változók tömbjében és a veremben eltárolt értékeket.

A felhasznált módszerek

A program C++ nyelven íródott, a <TODO> grafikus felület Qt-val készült, az assembly kód kezdeti elemzése, valamint menet közbeni értelmezése flex által generált lexikus elemzőt, illetve bisonc++ által generált szintaktikus és szemantikus elemzőt használ.

Hardver követelmények

<TODO>

Üzembe helyezés

<TODO>

A program kezelése

Felhasználói felület

<TODO>

A bemeneti fájlok szintaxisa

A program az x86 NASM assembly szintaxisát használja fel alapvetően, viszont az utasításkészlet korlátozott, és bizonyos pontokon vannak engedmények. Hogyha a bemenő fájl szintaxisa nem felel meg a leírtaknak, a program a kezdeti elemzés során hibát jelez.

Az alábbi leírásban használt jelölések:

- kulcsszó: a kulcsszó ugyanezzel az írásmóddal szerepelhet (általában kis-nagybetű nem számít)
- < … >: a pontok helyén szereplő kifejezés értelemszerű behelyettesítése

    - pl. <kettőspont> egy darab :-karaktert jelöl
    - pl. <azonosító> a program által azonosítóként elfogadott karaktersorozatokat jelöli
- < … | … | ... >: a függőleges vonalakkal elválasztott szavak közül pontosan egy szerepel

A regiszterek a következők:

- eax, ax, al, ah; ebx, bx, bl, bh; ecx, cx, cl, ch; edx, dx, dl, dh
    - az a, b, c vagy d betűkben megegyező regiszterek egyben vannak tárolva, egymással tartalmazásos kapcsolatban vannak
    - pl. az „eax” regiszter 4 byteos, az „ax” regiszter a két alacsony helyiértékű byteja
    - pl. ab „bx” regiszter alacsony helyiértékű byteja „bl”, a nagyobb helyiértékű byteja „bh”
- esp, sp; ebp, bp
    - a fentiekhez hasonlóan itt is tartalmazásos kapcsolat van esp-sp, illetve ebp-bp között
    - „esp” regiszter tartalma határozza meg, hogy a futásidejű veremben hány byte található
    - ezek a regiszterek hivatkozások esetén kitüntetett szerepben vannak – ha közülük egy szerepel, akkor a hivatkozás veremhivatkozás, különben a változók tömbjére hivatkozás
        - pl. „word [esp]” a verem tetejéről kezdve 2 byte

Lehet a bemeneti fájlban pontosvessző (;), ekkor annak a sornak a maradékát a program megjegyzésként kezeli és a szimuláció szempontjából figyelmen kívül hagyja.

A szintaxis tehát a következő:

- <szekciók> -ból épül fel a program, egy szekció a következők valamelyike lehet:
    - **section .data**
        - < <azonosító><kettőspont> <**db**|**dw**|**dd**> <kezdő értékek> kifejezések sorozata, szóközzel vagy sorvéggel elválasztva>

- változók deklarálása, megadott kezdeti értékkel, a későbbiekben <azonosító> névvel lehet rájuk hivatkozni
- a <kezdő értékek> számok (legalább egy darab) sorozata, vesszővel elválasztva
- minden egyes számhoz ami a <kezdő értékek>-ben van a méretjelölőtől függően le lesz foglalva 1(**db**), 2(**dw**) vagy 4(**dd**) byte és az adott számra a felsorolásból lesz inicializálva a változó értéke
  - amennyiben a szám túl nagy (pl. 1000 nem fér el 1 byteon), akkor a magas helyiértékek túlcsordulás miatt elvesznek, ekkor az alacsony helyiértékek nem maximumra, hanem a nekik megfelelő értékre inicializálódnak (fentebbi példa esetén: 1000 modulo 256 = 232-ra)
  - amennyiben a szám kicsi és nem tölti ki az összes megadott byteot, akkor kerülhetnek a magasabb helyiértékekre nullák (és a következő szám illetve változó nem csúszik előrébb)
  - pl: „x: **dw** 11, 66000” összesen 4 byteot foglal le x-nek, értékük helyiérték szerint növekvően 11, 0, 208, 1

◦ **section .bss**
- < <azonosító><kettőspont> <**resb**|**resw**|**resd**> <szám> kifejezések sorozata, szóközzel vagy sorvéggel elválasztva>
- változó deklarálása, minden byte 0-ra inicializálva
- a legfoglalt byteok száma <szám> * a méretjelölő értéke (**resb** = 1, **resw** = 2, **resd** = 4)
  - pl. „x: **resw** 3” kifejezés x-nek 3 * 2 = 6 byteot foglal le

◦ **section .text**
- <utasítások sorozata, szóközökkel vagy sortörésekkel elválasztva>
- a szekció elején lehet „global <azonosító>” kifejezés, ez jelöli majd a program belépési pontját, ahonnan a végrehajtás elkezdődik
  - pontosan egy helyen kell belépési pontot megjelölni, különben a program hibát jelez

◦ **global** <azonosító>
- megjelöli a program belépési pontját

        - lehet önállóan, nem csak text szekció elején
- <utasítás>
    - <azonosító><kettőspont>
        - megjelöl egy címkét az ugró utasításokhoz: amennyiben egy ugró utasítás <azonosító>-t jelöli meg céljául, akkor (amennyiben történik ugrás) a program végrehajtása a címke definícióját követő első utasítástól folytatódik
        - ha egy azonosító meg van adva ugrás célpontjaként, akkor a programnak pontosan egy címkét kell azzal az azonosítóval tartalmaznia
        - egy azonosító legfeljebb egy címkében szerepelhet
        - szerepelhet ugyanaz az azonosító egyszerre változóként és címkeként is (a hivatkozás kontextusából következik, hogy egy azonosító melyikként lesz értelmezve)
        - a címkéket a szimuláció nem kezeli önálló utasításként, a végrehajtás
        - <TODO> minden címkét követnie kell utasításnak – nem követhet címkét egy új szekció vagy fájl vége
    - ugró utasítások:
        - **jmp** <azonosító>
            - az <azonosító>-val megjelölt címkét követő utasítással folytatja a program végrehajtását (a továbbiakban ezt csak „ugrásnak” fogom nevezni)
            - minden ugró utasításnál van lehetőség a címke azonosítója előtt a „**near**” kulcsszó használatára, ennek a szimuláció szempontjából nincs hatása (viszont assembly kódban szerepelhet „hosszú” ugrások jelzésére)
        - **ja** <azonosító>
            - amennyiben a sign flag és a zero flag értéke is 0, ugrik
        - **jb** <azonosító>
            - amennyiben a sign flag értéke 1, és a zero flag értéke 0, ugrik
        - **je** <azonosító>; **jz** <azonosító>
            - amennyiben a zero flag értéke 1, ugrik

- **jna** <azonosító>
  - amennyiben a sign flag vagy a zero flag értéke 1, ugrik
- **jnb** <azonosító>
  - amennyiben a sign flag értéke 0, vagy a zero flag értéke 1, ugrik
- **jne** <azonosító>; **jnz** <azonosító>
  - amennyiben a zero flag értéke 0, ugrik
- **call** <azonosító>
  - elmenti 4 byteon a következő utasítás sorszámát a verembe, majd ugrik
- **ret**
  - kivesz a veremből 4 byteot, majd a következő utasítás sorszámát a kivett értékre állítja
  - amennyiben a verem teteje ugyanoda mutat, ahová az utolsó **call** utasítás végrehajtása után mutatott (és az az által eltárolt 4 byte nem változott), akkor az azt követő utasítástól folytatódik a végrehajtás – a **call** és a **ret** együtt körülbelül egy paraméterek nélküli függvényhívást valósítanak meg

A továbbiakban szereplő utasításoknál a következő jelöléseket alkalmazom:

- <hely>
  - egy olyan helyet jelöl, aminek az értéke módosítható lehet, azaz lehet regiszter, változó- vagy veremhivatkozás
  - hivatkozás esetén a szintaxis: [<érték>]
    - amennyiben az <érték> kifejezése tartalmaz „esp”, „ebp”, „sp” vagy „bp” regiszterre hivatkozást, akkor a veremből veszi ki az értéket a program, hogyha nem tartalmaz ilyet, akkor a változók tömbjéből
    - amennyiben a hivatkozás érvénytelen helyre mutat (olyan változókezdetre, ami nincs a változók tömbjének határain belül, vagy a veremnek egy olyan pontjára, ami nincs a verem teteje és alja között), akkor a program hibát jelez
- <érték>

    - lehet regiszter, <azonosító> vagy konstans, illetve ezekből felépülhet zárójelezésekkel, összeadás (+), kivonás (-), szorzás (*) és osztás (/) műveletekkel
        - <azonosító> esetén az értéke az adott változónak a változók tömbjében elfoglalt első bytejának sorszáma
    - lehet hivatkozás is, ekkor a hivatkozott helyen található byteokból a program előállít egy számot

A további utasításoknál fontos, hogy egyértelműnek kell lennie az argumentumok méretének, a méretet meghatározhatja regiszter vagy az egyik argumentum előtt szereplő **byte**, **word** vagy **dword** szavak (rendre 1, 2 és 4 byteos argumentumméretre utalnak). Amennyiben nincs méret megadva, vagy eltérő méretek vannak megadva, a program a kezdeti beolvasásnál hibát jelez.

- **mov** <hely>, <érték>
    - a <hely> által megjelölt helyre bemásolja az <érték>-ben szereplő értéket
- **add** <hely>, <érték>
    - a <hely>-en levő értékhez hozzáadja <érték>-et
    - amennyiben az összeadás eredménye 0 (nullák összeadásából, vagy túlcsordulás miatt), akkor a zero flag értékét 1-re állítja, különben 0-ra
- **sub** <hely>, <érték>
    - a <hely>-en levő értékből kivonja <érték>-et
    - amennyiben <érték> nagyobb mint a <hely>-en levő szám, akkor a sign flaget 1-re állítja, különben 0-ra
    - amennyiben a kivonás eredménye 0, a zero flaget 1-re állítja, különben 0-ra
- **and** <hely>, <érték>
    - „bitenkénti és” műveletet hajt végre a két argumentumon, az eredményt <hely>-en tárolja el
    - ha a művelet eredménye 0, a zero flaget 1-re állítja, különben 0-ra
- **or** <hely>, <érték>
    - „bitenkénti vagy” műveletet hajt végre a két argumentumon, az eredményt <hely>-en tárolja el

    - ha a művelet eredménye 0 (azaz mindkét argumentum értéke 0), a zero flaget 1-re állítja, különben 0-ra
- **xor** <hely>, <érték>
    - „bitenkénti kizáró vagy” műveletet hajt végre a két argumentumon, az eredményt <hely>-en tárolja el
    - ha a művelet eredménye 0 (a két argumentum egymás bitenkénti komplementere), akkor a zero flaget 1-re állítja, különben 0-ra
- **inc** <hely>
    - a <hely>-en található szám értékét megnöveli eggyel
    - túlcsordulás esetén a zero flaget 1-re állítja, különben 0-ra
- **dec** <hely>
    - a <hely>-en található szám értékét csökkenti eggyel
    - ha az érték 0-ra csökken, akkor a zero flaget 1-re állítja, különben 0-ra
- **not** <hely>
    - „bitenkénti nem” műveletet hajt végre a <hely>-en, azaz minden bitet lecserél a komplementerére
    - ha a művelet eredménye 0 (csupa egyes volt a <hely>-en a művelet előtt), akkor a zero flaget 1-re állítja, különben 0-ra
- **cmp** <érték>, <érték>
    - összehasonlítja a két értéket
    - ha megegyeznek, a zero flaget 1-re állítja, különben 0-ra
    - ha az első szám kisebb a másodiknál, a sign flaget 1-re állítja, különben 0-ra
- **mul** <érték>
    - <érték>-nek megadott argumentummérettől függően szorzást végez el
        - ha 1 byteos, akkor „al” regiszterrel szorozza meg, és „ax”-ben tárolja el a szorzás eredményét
        - ha 2 byteos, akkor „ax” regiszterrel szorozza meg, „ax”-ben tárolja el az eredmény kisebb helyiértékű 2 byteját és „dx”-ben a nagyobb helyiértékű 2 byteját

        - ha 4 byteos, akkor „eax” regiszterrel szorozza meg, „eax” regiszterben tárolja el az eredmény 4 alsó helyiértékét és az „edx”-ben a 4 felső helyiértékét
    - ha az eredmény 0, akkor a zero flag értékét 1-re állítja, különben 0-ra
- **div** <érték>
    - <érték>-nek megadott argumentummérettől függően maradékos osztást végez el
        - ha 1 byteos, akkor az „ax” regiszter tartalmát elosztja <érték>-kel, az eredmény „al”-be, a maradék „ah”-ba kerül
        - ha 2 byteos, akkor összefűzi a „dx” és az „ax” regisztereket 4 byteon (ennek nincs nyoma a regisztererekben), ezt elosztja <érték>-kel, az eredmény „ax”-be, a maradék „dx”-be kerül
        - ha 4 byteos, akkor összefűzi az „edx” és az „eax” regisztereket 8 byteon, ezt elosztja <érték>-kel, az eredmény „eax”-be, a maradék „edx”-be kerül
- **push** <érték>
    - a futásidejű verem tetejére (ami az „esp” regiszter tartalmaz határoz meg) eltárolja <érték>-et az argumentum méret által meghatározott számú byteon, és az „esp” regiszter értékét ennek megfelelően módosítja
    - ha az eltárolás után 268.435.455-nél több byteot tartalmaz a verem, a program hibát jelez
- **pop** <hely>
    - a futásidejű verem tetejéről elvesz az argumentummméretnek megfelelő számú byteot, és <hely>-re eltárolja
    - amennyiben a veremben nincs annyi byte, amennyit a művelet ki akar venni, a program hibát jelez
    - az „esp” regiszter értékét megfelelően módosítja

Fejlesztői dokumentáció

A program feladata

A program célja, hogy egy x86 NASM assembly utasításokat használó programot utasításonként szimuláljon, azaz minden utasítás után megjelenítse, hogy a program milyen adatokat tárol a regiszterekben, a változókban és a futásidejű veremben.

Megkötések

A program csak bizonyos utasítások felismerésére és végrehajtására képes, ezek a következők:

***mov*, *add*, *sub*, *and*, *or*, *xor*, *cmp*, *inc*, *dec*, *not*, *mul*, *div*; *push*, *pop*; *jmp*, *ja*, *jb*, *je*, *jz*, *jna*, *jnb*, *jne*, *jnz*, *call*, *ret*;**

valamint csak bizonyos regisztereket kezel:

eax, *ebx*, *ecx*, *edx*, *ax*, *bx*, *cx*, *dx*, *ah*, *al*, *bh*, *bl*, *ch*, *cl*, *dh*, *dli esp*, *ebp*, *sp*, *bp*.

Ezek mellett a szokásos módon lehet változókat deklarálni és inicializálni, belépési módot megadni, sor végéig kommentet írni (amit a szimuláció figyelmen kívül hagy), illetve címkéket elhelyezni (amikhez az ugró utasítás léptetheti a végrehajtást).

A könnyebb használat érdekében bizonyos helyeken nagyobb szabadságot adunk a felhasználónak:

- van lehetőség arra, hogy egy utasításnak mindkét argumentuma memória-hivatkozás legyen (normál esetben legfeljebb az egyik lehet az, a másiknak mindenképp regiszternek vagy konstansnak kell lennie)
- amikor valamilyen konstans szám-értéket akar a programban megadni, lehetőség van arra, hogy aritmetikai műveletek sorozatával adja meg
  - pl: **mov** eax, 256 * 256 * 4 + 256 * 11 + 37

A felhasznált módszerek

A program C++ nyelven íródott, a lexikális elemzést flex által generált lexikális elemző csinálja, a szintaktikus és szemantikus elemzést bisonc++ által generált elemző hajtja végre.

Osztálydiagram

<TODO>

Az egyes osztályok diagramjai, leírásai

Allapot

Az ábrázolásnál a tárolt adatok bytejait minden esetben *unsigned char* típussal tároljuk. Ez az osztály az adott bemeneti fájlra egyértelműen meghatározza, hogy a szimulációnak melyik pontján vagyunk.

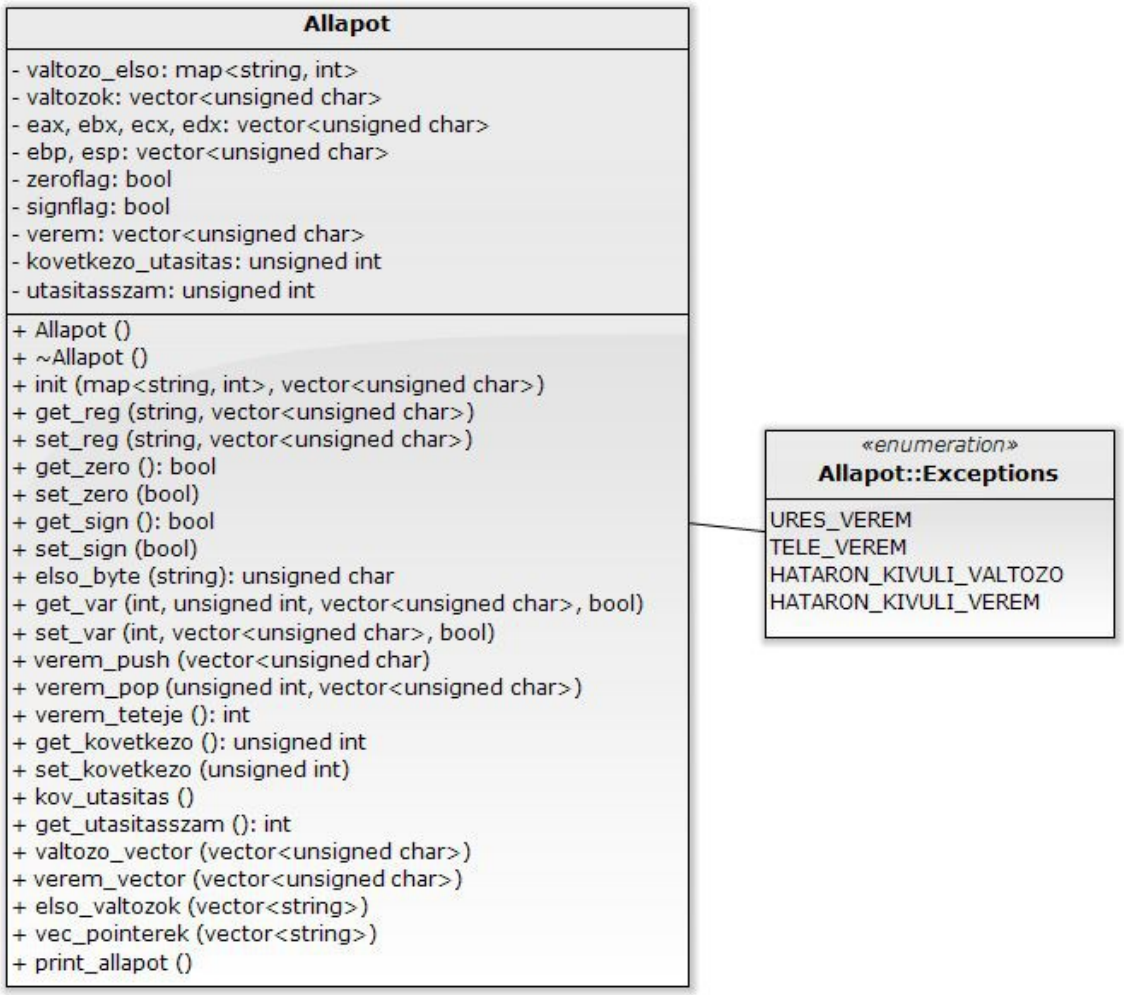

Adattagok:

- *valtozok*: a változók bytejainak tömbje
- *valtozo_*elso: azonosítókhoz tárolja a változók tömbben hozzá tartozó első byte sorszámát
- *eax*, *ebx*, *ecx*, *edx*, *ebp*, *esp*: regiszterek tömbje
- *zeroflag*, *signflag*: a megfelelő flag aktuális értéke
- *verem*: a veremben tárolt byteok tömbje
- *kovetkezo_utasitas*: a következő utasítás sorszáma
- *utasitasszam*: az eddig végrehajtott utasítások száma

Metódusok:

- Allapot(): konstruktor, inicializálja a regisztereket, a vermet és a flageket
- ~Allapot(): destruktor, jelenleg nem csinál semmit
- init(map<string, int>, vector<unsigned char>): a megadott mappel inicializálja *valtozo_elso*-t, a vektorral pedig *valtozok*-at
- get_reg(string, vector<unsigned char>): a megadott vektorba kimásolja a stringben megadott nevű regiszter értékét
- set_reg(string, vector<unsigned char>): a stringben megadott nevű regiszterbe bemásolja a vektor tartalmát
- get_zero(): visszaadja a *zeroflag* értékét
- set_zero(bool): beállítja a *zeroflag* értékét
- get_sign(), set_sign(bool): ugyanezek, csak a *signflag*re
- elso_byte(string): visszadja a stringben megnevezett változó első bytejának sorszámát
- get_var(int, unsigned int, vector<unsigned char>, bool)
  - az int megadja az első byte sorszámát, az unsigned int a lekérdezett byteok számát, a vektor a cél ahova kimásolja a byteokat
  - ha a bool hamis (alapértelmezett), akkor a változók tömbjéből vesz ki, ha igaz, akkor a verem tömbjéből
  - dobhat HATARON_KIVULI_VALTOZO és HATARON_KIVULI_VEREM kivételt, ha az első byte és/vagy a hossz érvénytelen hivatkozást eredményez
- set_var(int, vector<unsigned char>, bool)

    - az intben megadott első byte sorszámától kezdve bemásolja a *valtozok* tömbbe a vektorban megadott értékeket (a darabszámot a vektor hossza határozza meg)
    - ha a bool hamis (alapértelmezett), akkor a változók tömbjét módosítja, ha igaz, akkor a verem tömbjét
    - dobhat HATARON_KIVULI_VALTOZO és HATARON_KIVULI_VEREM kivételt, ha az első byte és/vagy a vektor hossza érvénytelen hivatkozást eredményez
- verem_push(vector<unsigned char>)
    - eltárolja a verembe a vektor tartalmát, *esp* regisztert megfelelően módosítva
    - dobhat TELE_VEREM kivételt, hogyha a veremben a művelet után 268435455-nál több byte van
- verem_pop(unsigned int, vector<unsigned char>)
    - a verem tetejéről kivesz az intben megadott számú byteot, és a vektorba másolja, *esp* regisztert megfelelően módosítva
    - dobhat URES_VEREM kivételt, ha a veremben nincs annyi byte, ahányat ki akar venni
- verem_teteje(): az *esp* regiszter alapján megmondja, hány byte van a veremben
- get_kovetkezo(): megadja a következő utasítás sorszámát
- set_kovetkezo(unsigned int): beállítja a következő utasítás sorszámát
- kov_utasitas(): a *utasitasszam* értékét eggyel növeli
- get_utasitasszam(): visszaadja az *utasitasszam* értékét
- valtozo_vector(vector<unsigned char>), verem_vector(vector<unsigned char>): a megadott tömbbe másolja a lekérdezett tömb elemeit
- elso_valtozok(vector<string>): a megadott tömböt feltölti üres stringekkel vagy az adott sorszámon elkezdődő változó nevével (a *valtozo_elso* mapből)
- vec_pointerek(vector<string>): a megadott tömböt feltölti üres stringekkel, illetve ahova az *esp*, *ebp*, regiszter mutat, oda a megfelelő névvel

- print_allapot(): kiírja a standard kimenetre az objektum tartalmát